

## UNIVERSITÉ IBN ZOHR FACULTÉ DES SCIENCES DÉPARTEMENT D'INFORMATIQUE

#### Master Spécialisé

Systèmes Informatiques Distribués & Big Data

Guide de Configuration Projet d'Analyse En Temps Réel des données de Trafic Aérien

Réaliser par :

Encadré par :

Boujarfaoui Ayman

En-nahel Aissam

Ayoub Ellaouzi

El-adarissi Abdelaziz

Professeur Mr.Karim Afdel

# Table des matières

1	Con	Configuration d'événement			
	1.1	Téléchargement	2		
	1.2	Installation	6		
	1.3	Modifications dans les variables d'environnement	11		
	1.4	Kibana et Elasticsearch	16		
2	Test	d'Application	18		

# Table des figures

## Introduction

Notre projet, intitulé "Analyse en temps réel des données de trafic aérien à l'aide d'Apache Spark et Kafka Framework", vise à mettre en œuvre un système de traitement en temps réel des données de trafic aérien en utilisant deux technologies : Apache Kafka et Apache Spark.

L'objectif principal est de collecter les données de trafic aérien en temps réel à partir de l'API "Flight Tracker API and Data - Aviation database and API" et de les analyser en continu pour fournir des informations en temps réel sur le trafic aérien.

Apache Kafka joue un rôle crucial en tant que système de messagerie distribuée, facilitant ainsi la collecte et la gestion des flux de données en temps réel. Les données de trafic aérien collectées seront acheminées vers les topics correspondants, où elles seront prêtes à être traitées par Apache Spark. D'autre part, Apache Spark est un framework de traitement de données en temps réel offrant des fonctionnalités avancées de traitement distribué et d'analyse. En configurant Apache Spark Streaming, nous pourrons mettre en place des tâches de traitement en temps réel pour analyser les données de trafic aérien provenant de Kafka.

La relation étroite entre Apache Kafka et Apache Spark est cruciale dans ce projet, car Kafka agit en tant que fournisseur de données en temps réel pour Spark. En utilisant Kafka comme source de données pour Spark Streaming, nous assurons un flux continu de données pour une analyse en temps réel efficace.

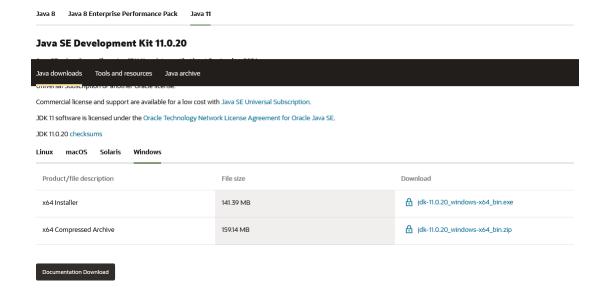
Ce projet offre une opportunité passionnante de mettre en pratique nos connaissances sur Apache Spark et Kafka Framework, en développant un système de traitement en temps réel fonctionnel pour l'analyse des données de trafic aérien.

# Chapitre 1

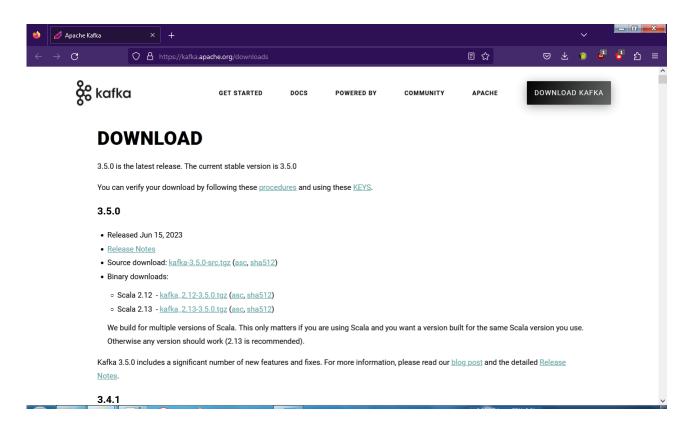
# Configuration d'événement

## 1.1 Téléchargement

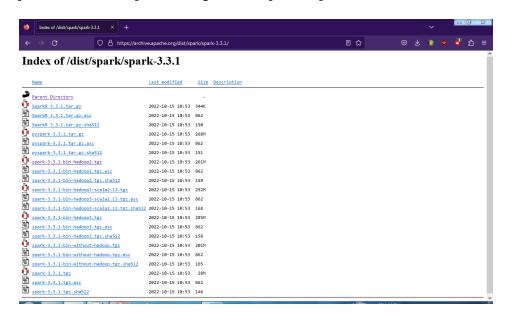
 Télécharger JDK 1.8 dans le site officiel d'oracle https://www.oracle.com/java/technologies/downloads/



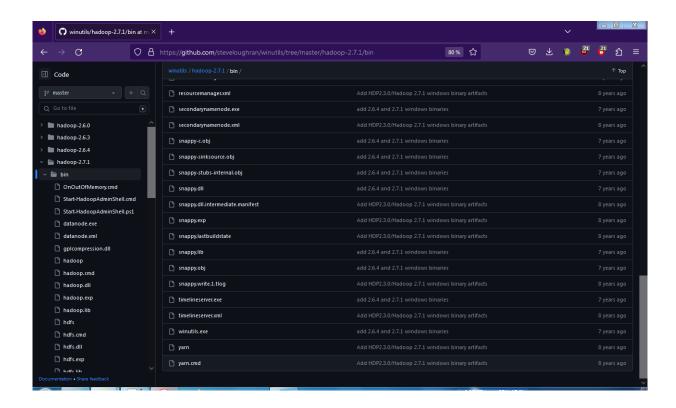
• Téléchargement d'Apache Kafka version 3.5.0 (kafka\_2.12-3.5.0) https://kafka.apache.org/downloads



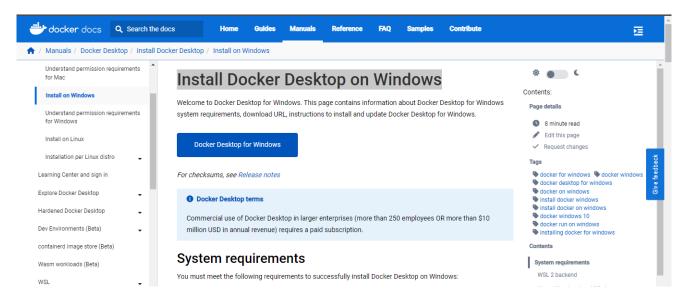
• Téléchargement d'Apache Spark (spark-3.3.1) https://archive.apache.org/dist/spark/spark-3.3.1/



 Téléchargement de la version appropriée de winutils.exe pour Hadoop https://github.com/steveloughran/winutils/blob/master/hadoop-2.7.1/bin/winutils.exe



 Install Docker Desktop on Windows https://docs.docker.com/desktop/install/windows-install/



• Télécharger le package de mise à jour du noyau Linux WSL https://learn.microsoft.com/fr-fr/windows/wsl/install-manual#step-4---/download-the-linux-kernel-update-package



 Install pyspark from pip pip install pyspark

```
C:\Windows\system3\cMD.exe-pip install pyspark
Microsoft Windows (version 10.0.19045.3324]
(c) Microsoft Corporation. Tous droits réservés.

C:\Users\Paname>pip install pyspark
Collecting pyspark
Downloading pyspark-3.4.1.tar.gz (310.8 MB)

Preparing metadata (setup.py) ... done
Collecting py4j==0.10.9.7
Downloading py4j==0.10.9.7
Downloading py4j=-0.10.9.7-py2.py3-none-any.whl (200 kB)

Jsing legacy 'setup.py install' for pyspark, since package 'wheel' is not installed.
Installing collected packages: py4j, pyspark
Running setup.py install for pyspark ... |
```

#### Test the PySpark Installation

```
C: C\Windows\system32\CMD.exe - pyspark
Microsoft Windows { version 10.0.19045.3324} { (c) Microsoft Corporation. Tous droits réservés.

C:\Usens\Paname>pyspark
Python 3.9.13 { tags/v3.9.13:6de2ca5, May 17 2022, 16:36:42) [MSC v.1929 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.

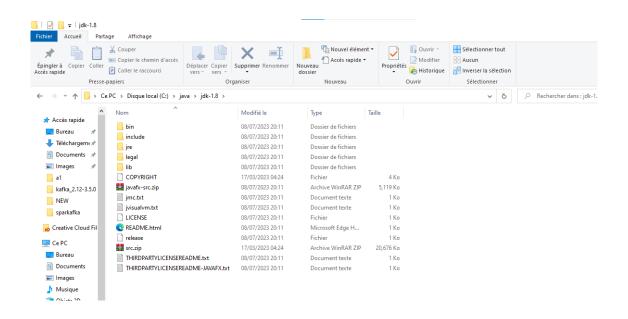
Setting default log level to "MARN".

To adjust logging level use sc.setlogLevel(newLevel). For SparkR, use setLogLevel(newLevel).
23/68/21 14:35:52 WARN NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable Welcome to

\[ \frac{1}{\sqrt{1}} \
```

#### 1.2 Installation

• Apres l'installation du Java jdk-8u371-windows-x64.exe dans C :/Java/



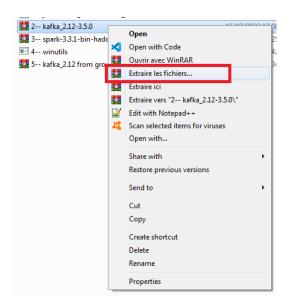
• Test JDK Version

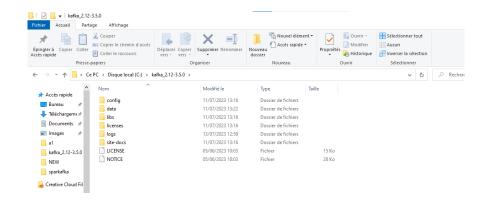
```
C:\Windows\system32\CMD.exe

C:\Users\Paname>java -version
java version "1.8.0_371"
Java(TM) SE Runtime Environment (build 1.8.0_371-b11)
Java HotSpot(TM) 64-Bit Server VM (build 25.371-b11, mixed mode)

C:\Users\Paname>
```

• Aprés On va décompresser l'archive kafka\_2.12-3.5.0.tgz dans le répertoire C:/



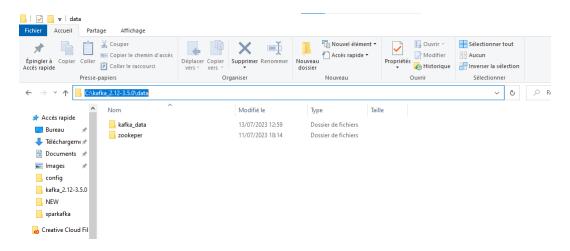


• On va modifier une ligne dataDir dans C:\kafka\\_2.12-3.5.0\config\zookeeper. properties par dataDir=C:/kafka\_2.12-3.5.0/data/zookeper

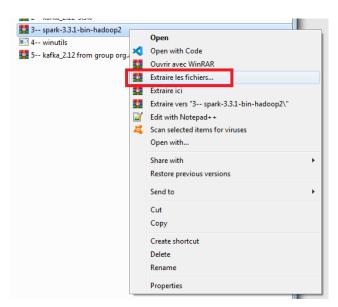
• Et On va modifier une ligne dans C :/kafka/\_2.12-3.5.0/config/server.properties log.dirs=C :/kafka\_2.12-3.5.0/data/kafka\_data

```
≺ File Edit Selection View Go Run …
                                                                                                  Ð
       C: > kafka_2.12-3.5.0 > config > 💠 server.properties
                                                                                                                                            Aa <u>ab</u> * 1 of 12
              num.network.threads=3
ညိ
               num.io.threads=8
              # The send buffer (SO_SNDBUF) used by the socket server
               socket.send.buffer.bytes=102400
         50
51
52
53
54
55
56
57
58
socket.receive.buffer.bytes=102400
Ġ
              # The maximum size of a request that the socket server will accept (protection against 00M)
socket.request.max.bytes=104857600
         59
60
                        ma separated list of directories under which to store log files
               log.dirs=C:/kafka_2.12-3.5.0/data/kafka_data
              # The default number of log partitions per topic. More partitions allow greater # parallelism for consumption, but this will also result in more files across
```

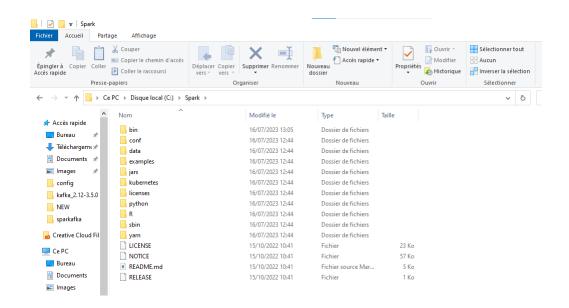
 Donc il faut crée les 2 répertoires C :/kafka\_2.12-3.5.0/data/kafka\_data et C :/kafka\_2.12-3.5.0/data/zookeper



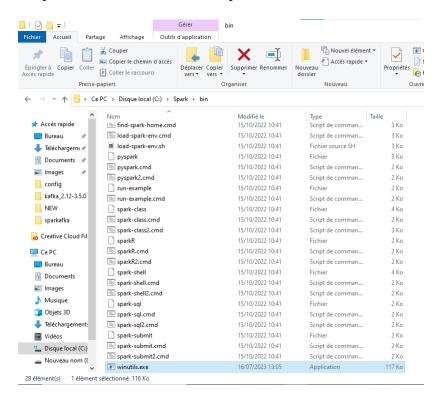
• l'etape suivant est de décompresser l'archive spark-3.3.1-bin-hadoop2.tgz dans le répertoire C :/spark



Chapitre 1 Configuration d'événement

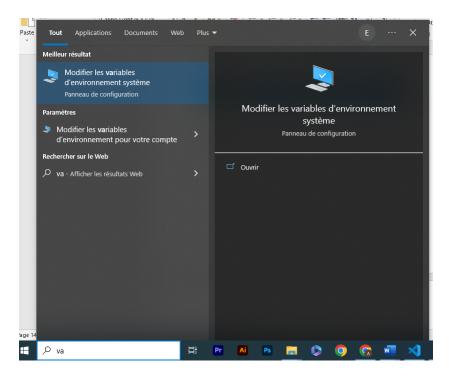


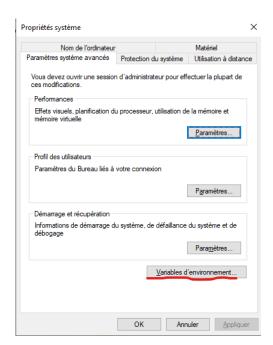
• Puis on va déplacer winutils.exe dans C :/spark/bin/



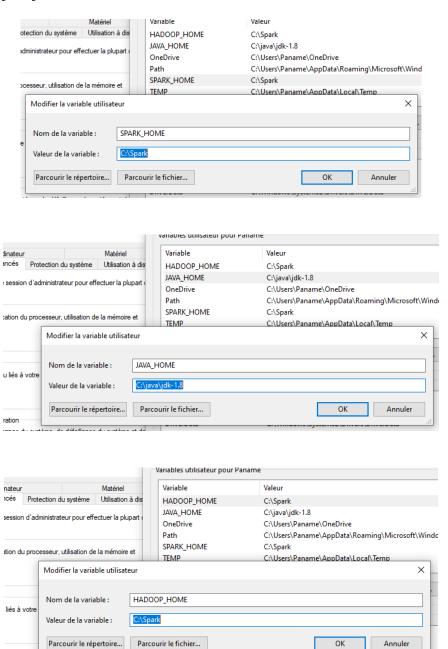
## 1.3 Modifications dans les variables d'environnement

• Dans la bare de recherche taper variable d'environnement



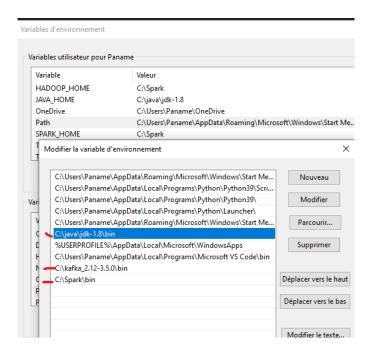


• Ajouter les paths suivants : SPARK\_HOME : C :/spark et HADOOP\_HOME : C :/spark et C :/java/jdk-1.8

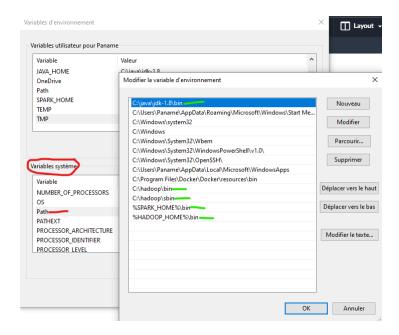


ation

• Ajouter aussi les pathes suivants dans Path de utilisateur



• Ajouter aussi les pathes suivants dans path de système



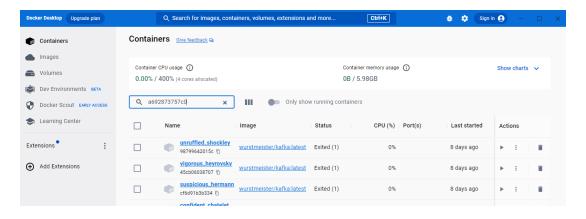
#### 1 Configuration de Docker Compose

 Créer une fichier docker-compose.yml qui contient des images(containers) Zookeeper, Kafka server, Kibana et Elasticsearsh

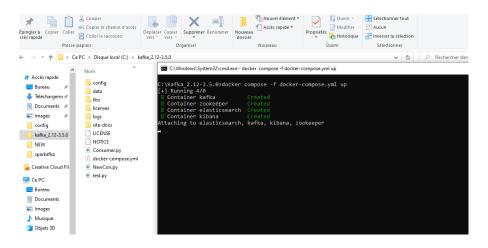
```
version: '3.7'
3 services:
        zookeeper:
          image: wurstmeister/zookeeper
          ulimits:
            nofile:
              soft: 65536
              hard: 65536
          container_name: zookeeper
          ports:
            - "2181:2181"
12
        kafka:
          image: wurstmeister/kafka
          container_name: kafka
15
          ports:
            - "9092:9092"
          environment:
18
            KAFKA_ADVERTISED_HOST_NAME: localhost
            KAFKA_ZOOKEEPER_CONNECT: zookeeper:2181
        elasticsearch:
21
          image: docker.elastic.co/elasticsearch/elasticsearch:7.4.0
          container_name: elasticsearch
23
          restart: always
          environment:
            - xpack.security.enabled=false
26
            - discovery.type=single-node
          ulimits:
            memlock:
              soft: -1
              hard: -1
            nofile:
              soft: 65536
              hard: 65536
          cap_add:
            - IPC_LOCK
          volumes:
37
            - elasticsearch-data-volume:/usr/share/elasticsearch/data
          ports:
            - 9200:9200
```

```
- 9300:9300
41
        kibana:
43
          container_name: kibana
          image: docker.elastic.co/kibana/kibana:7.4.0
          restart: always
46
          environment:
47
            - ELASTICSEARCH_HOSTS=http://elasticsearch:9200
          ports:
            - 5601:5601
50
          depends_on:
51
            - elasticsearch
volumes:
    elasticsearch-data-volume:
      driver: local
```

#### puis Lancer l'Application de Docker déja installer

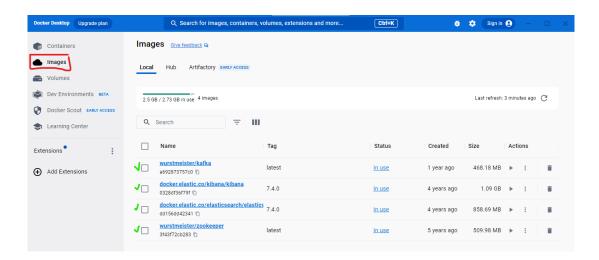


#### Et apres Taper la commande suivante



Finalement les containers seront bien installés

Chapitre 1 Configuration d'événement



#### 1.4 Kibana et Elasticsearch

#### Elasticsearch

En quelques mots, nous aidons les utilisateurs à trouver plus rapidement ce qu'ils recherchent, qu'il s'agisse de collaborateurs ayant besoin de documents sur votre intranet ou de clients sur internet en quête de la paire de chaussures idéale. Pour aller un peu plus loin sur le plan technique, voici ce qu'on pourrait dire :

Elasticsearch est un moteur de recherche et d'analyse distribué gratuit et ouvert pour toutes les données (textuelles, numériques, géospatiales, structurées et non structurées). Elasticsearch a été conçu à partir d'Apache Lucene et a été lancé en 2010 par Elasticsearch N. V. (maintenant appelé Elastic). Réputé pour ses API REST simples, sa nature distribuée, sa vitesse et sa scalabilité, Elasticsearch est le composant principal de la Suite Elastic, un ensemble d'outils gratuits et ouverts d'ingestion de données, d'enrichissement, de stockage, d'analyse et de visualisation. Couramment appelée la Suite ELK (pour Elasticsearch, Logstash et Kibana), la Suite Elastic comprend désormais une riche collection d'agents de transfert légers, appelés les agents Beats, pour envoyer des données à Elasticsearch.

#### Kibana

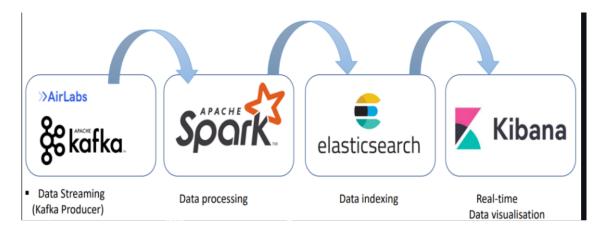
Kibana est une application frontend gratuite et ouverte qui s'appuie sur la Suite Elastic. Elle permet de rechercher et de visualiser les données indexées dans Elasticsearch. Si Kibana est connue pour être l'outil de représentation graphique de la Suite Elastic (précédemment appelée "la Suite ELK", acronyme d'Elasticsearch, Logstash et Kibana), elle sert aussi d'interface utilisateur pour le monitoring, la gestion et la sécurité des clusters de la Suite Elastic. Sans oublier qu'elle joue aussi le rôle de hub centralisé pour des solutions intégrées, développées sur

la Suite Elastic. Créée en 2013 au sein de la communauté Elasticsearch, Kibana s'est développée pour offrir une vue à 360° sur la Suite Elastic, devenant ainsi un véritable portail pour les utilisateurs et les entreprises.

# Chapitre 2

## Test d'Application

Dans ce projet, nous utiliserons une API de suivi de vols en temps réel, Apache Kafka, Elasticsearch et Kibana pour créer un pipeline de données d'informations de vol en temps réel et suivre les vols en direct. Nous utiliserons une architecture de haut niveau ainsi que les configurations correspondantes qui nous permettront de créer ce pipeline de données. Le résultat final sera un tableau de bord Kibana récupérant des données en temps réel à partir d'Elasticsearch.

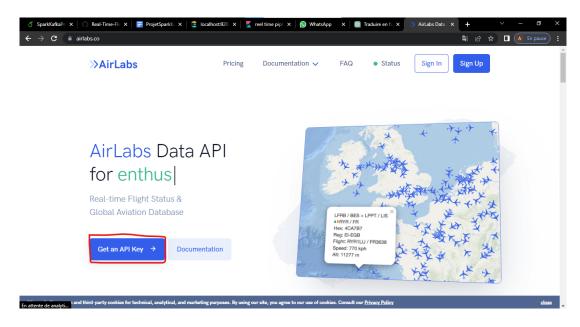


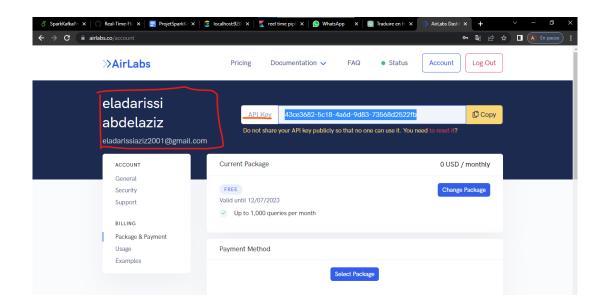
Nous avons commencé par collecter en temps réel des informations de vol "Flight Tracker API and Data - Aviation database and API"(numéro d'immatriculation de l'aéronef, latitude géographique de l'aéronef, longitude géographique de l'aéronef, élévation de l'aéronef, numéro de vol, etc.) et nous les avons ensuite envoyées à Kafka pour l'analyse.

```
> $ curl https://airlabs.co/api/v9/flights

[{
    "hex": "76CCCO",
    "reg_number": "9V-SFM",
    "flight_iata": "SQ7371",
    "flight_icao": "SIA7371",
    "lat": 21.366613, "lng": 66.61321,
    "ait": 10021, "dir": 121,
    "speed": 966, "v_speed": -0.3,
    "airline_iata": "SQ", "airline_icao": "SIA",
    "dep_iata": "AMS", "dep_icao": "EHAM",
    "arr_iata": "SIN", "arr_icao": "WSSS",
    "flag": "SG", "aircraft_icao": "8744",
    "squawk": "3420", "updated": 1611366621
}]
```

il faut créer une compte dans ce site https://airlabs.co/ pour avoir le KEY API et le clé secret





L'étape suivante consiste à créer un topic (test-topic) pour stocker les informations qui seront produites par le producteur.(Programme Java)

```
kafka-topics.bat --create --topic test-topic --bootstrap-server localhost :9092 --partitions 2 --replication-factor 2
```

Puis Démarrer les serveurs kafka, zookeeper, Kibana et Elastic Search

```
C:\Xafka 2.12-3.5.80docker compose up

[a] Running 4/8

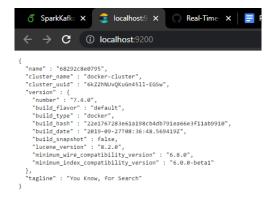
Container elasticsearch Created

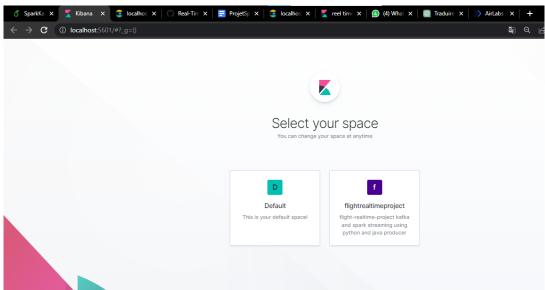
Container zookeeper Created

Container kibana Created

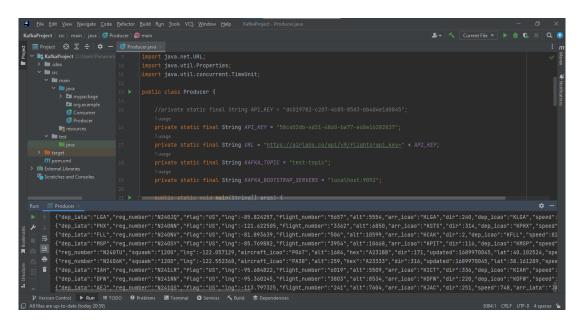
Cont
```

Pour ElasticSearch Vous pouvez accéder à http://localhost:9200 pour vérifier s'il est actif et opérationnel.et Kibana http://localhost:5601





Les données sont récupérées à partir de l'API de flux de données de vol et envoyées vers un topic Kafka à l'aide de Programme Java(Producer.java) qui Nous avous créer.



En fin On va démarrer le programme Python (Consumer.py) pour collecter périodiquement des données en temps réel à partir du topic Kafka et les envoyer dans un index Elasticsearch.EN Utlisant la commande suivante

```
spark-submit --packages org.apache.spark:spark-sql-kafka-0-10_2.12:3.1.2, org.elasticsearch:elasticsearch-spark-30_2.12:7.14.2 Consumer.py
```

```
| Selection | Selection | View | Go | Run | Consumerary |
```

#### **Dashboard Final**

